



Fachhochschule der Wirtschaft
FHDW Bielefeld

Studienarbeit im Modul Classification and Clustering

Kundensegmentierung mit RetailRocket und Online Retail II

Vorgestellt von:

Christian Roth

Senner Straße 68

33647 Bielefeld

`christian.roth@edu.fhdw.de`

Studiengang:

Wirtschaftsinformatik mit Schwerpunkt Data Science (*M.Sc.*)

Prüferin:

Prof. Dr. Yvonne Gorniak

Eingereicht am:

30. September 2025 in Bielefeld

Gendererklärung

Aus Gründen der besseren Lesbarkeit wird auf die gleichzeitige Verwendung der Sprachformen männlich, weiblich und divers (m/w/d) verzichtet. Sämtliche Personenbezeichnungen gelten gleichermaßen für alle Geschlechter.

Abstract

Kunden im E-Commerce verhalten sich sehr unterschiedlich in ihrer Kaufhäufigkeit, ihren Ausgaben und ihrer Reaktion auf Kampagnen. Für Unternehmen liegt darin eine große Chance, denn differenzierte Kundensegmente ermöglichen eine gezieltere Ansprache, nachhaltigere Bindung und wirksamere Sortimentsentscheidungen. Gleichzeitig stellt diese Vielfalt eine Herausforderung dar, da sich Strukturen in den Daten nicht unmittelbar erschließen und klassische Auswertungen oft oberflächlich bleiben.

Diese Arbeit möchte die Forschungsfrage beantworten, welche Segmentstrukturen sich in E-Commerce-Daten verbergen und wie diese so beschrieben werden können, dass Marketing und CRM sie unmittelbar nutzen können. Clustering wird dabei nicht als Selbstzweck verstanden, sondern als Werkzeug, das Datenmuster sichtbar macht und in verständliche Profile übersetzt.

Das Vorgehen orientiert sich am CRISP-DM-Modell. Durch Feature Engineering werden Kennzahlen wie Recency, Frequency und Monetary Value sowie Warenkorb- und Sortimentsmerkmale gebildet. Die Segmentierung erfolgt mit K-Means für kompakte Strukturen und HDBSCAN für dichte-basierte Cluster. Die Qualität wird mit dem Silhouette-Koeffizienten und dem DBCV-Index bewertet. Die Hopkins-Statistik wird ergänzend zur Prüfung der Clustertendenz eingesetzt, ihre Aussagekraft für hochdimensionale, sparse Daten jedoch kritisch eingeordnet.

Die Ergebnisse zeigen mehrere unterscheidbare Segmente, die durch Kennzahlentabellen, Personas und Visualisierungen anschaulich dargestellt werden. Damit können Fachbereiche die Segmente für Kampagnen, Kundenbindungsprogramme und Sortimentsentscheidungen einsetzen. Die Arbeit zeigt, dass sich Segmentstrukturen in E-Commerce-Daten identifizieren, verständlich aufbereiten und in handlungsleitende Marketingmaßnahmen überführen lassen. Ein Ausblick skizziert die Ergänzung durch externe Validierung, Text-Mining und dynamische Segmentierungen.

Inhaltsverzeichnis

Gendererklärung	i
Abstract	ii
Inhaltsverzeichnis	iii
Abbildungsverzeichnis	iv
Tabellenverzeichnis	v
1 Einleitung	1
1.1 Problemstellung	1
1.2 Zielsetzung	1
1.3 Vorgehensweise	2
2 Theoretischer Hintergrund	3
2.1 Kundensegmentierung im E-Commerce	3
2.2 Clustering als Mittel zum Zweck	3
3 Datenbasis und Aufbereitung	5
3.1 Roadmap der Segmentierung im Projekt	5
3.2 Datensätze Online Retail II / RetailRocket	6
4 Methodik (CRISP-DM: Modeling - Theoretische Grundlagen)	7
4.1 Feature Engineering & Preprocessing (RFM, Warenkorbgrößen, Sortimentsmerkmale – konzeptionell)	7
4.2 Clustering-Verfahren (K-Means, HDBSCAN - zentrale Eigenschaften) . . .	8
4.3 Validierung (Hopkins, Silhouette, DBCV) als Qualitätskontrolle	8
5 Ergebnisse und Diskussion (CRISP-DM: Modeling und Evaluation - praktisch)	11

5.1	Preprocessing (Bereinigung, Skalierung, Variablenableitung – Resultate, Details in Anhang C)	11
5.2	Clustering (K-Means und HDBSCAN – Ergebnisse und Validierung)	11
5.3	Interpretation der Segmente (Clusterprofile, Personas, Visualisierungen) . .	12
5.4	Vergleich der Verfahren	12
6	Fazit und Ausblick	13
6.1	Beantwortung der Forschungsfrage	13
6.2	Limitationen	13
6.3	Ausblick (z. B. Text Mining, Echtzeit-Segmentierung)	14
	Literaturverzeichnis	15
	Anhang	16
	Anhangsverzeichnis	16
	Anhang A: Prozessmodelle	17
	A.1: Das CRISP-DM-Modell	18
	A.2: Segmentation Management Strategy	19
	Anhang B: Clustering und RFM	21
	B.1: Eindimensionale RFM-Segmentierung	22
	B.2: Mehrdimensionale RFM-Segmentierung	22
	B.3: Retail-Segmentierung mit RFM	23
	Anhang C: Data Preparation und Zusatzanalysen	27
	C.1: Bereinigung (fehlende Werte, Duplikate, Rückgaben)	27
	6.3.1 Verteilungen der E-Commerce Kennzahlen	33
	6.3.2 Korrelationsstruktur der Variablen	33
	6.3.3 Scatterplot-Matrix wichtiger Beziehungen	33
	6.3.4 Standardisierte Verteilungen im Vergleich	33
	C.2: Skalierung und Transformation	38
	C.3: Explorative Datenanalyse (zusätzliche Plots, Tabellen, Code)	38
	Glossar	39

Abbildungsverzeichnis

3.1	Eigene Darstellung der Segmentierungs-Roadmap mit Transformation von Rohdaten über Cluster und Segmente hin zu strategischen Maßnahmen . . .	6
A.1	Das CRISP-DM-Modell nach Wirth und Hipp (2000), S. 5	18
A.2	Roadmap der Segmentation Management Strategy nach Tsiptsis und Chorianopoulos (2010), S. 213–216	19
A.3	Beispiel für eindimensionale RFM-Einteilungen in fünf Quantile je Dimension. Hervorgehoben ist die RFM-Zelle 351 (Recency = 3, Frequency = 5, Monetary = 1) nach Tsiptsis und Chorianopoulos (2010), S. 336.	22
A.4	Eigene Darstellung eines RFM-Würfels	26
A.5	Verteilungen der wichtigsten Variablen	34
A.6	Korrelationsmatrix der E-Commerce Variablen	35
A.7	Wichtige Scatterplot-Beziehungen	36
A.8	Standardisierte Verteilungen im Vergleich	36

Tabellenverzeichnis

1 Einleitung

1.1 Problemstellung

Der Onlinehandel hat sich zu einem der wichtigsten Vertriebskanäle entwickelt. Millionen von Kunden kaufen regelmäßig ein, doch ihre Verhaltensweisen unterscheiden sich erheblich. Manche Kunden tätigen häufig kleine Käufe, andere bestellen selten, geben dabei aber hohe Summen aus. Hinzu kommen Unterschiede in der Sortimentswahl, im Preisbewusstsein und in der Reaktion auf Kampagnen.

Für Unternehmen liegt darin einerseits eine große Chance, da differenzierte Segmente eine gezielte Ansprache und Bindung ermöglichen. Andererseits stellt diese Vielfalt eine Herausforderung dar. Klassische Auswertungen wie Umsatzstatistiken oder Produktlisten zeigen nur an der Oberfläche Unterschiede, erfassen aber nicht die zugrunde liegenden Strukturen. Viele Segmentierungsprojekte scheitern daran, dass sie entweder methodisch zu stark auf Verfahren fokussieren oder dass die Ergebnisse nicht in verständliche, umsetzbare Formate übersetzt werden.

1.2 Zielsetzung

Die Arbeit möchte die Forschungsfrage beantworten, welche Segmentstrukturen sich in E-Commerce-Daten verbergen und wie diese so dargestellt werden können, dass sie für Marketing und CRM unmittelbar nutzbar sind. Mit den Segmentprofilen, den Personas und den daraus abgeleiteten Maßnahmen wird gezeigt, wie Datenmuster in klare Handlungsoptionen übersetzt werden können. Clustering wird dabei als Werkzeug verstanden, nicht als Selbstzweck.

Der Beitrag dieser Arbeit liegt in drei Aspekten. Erstens wird ein nachvollziehbarer

Prozess von der Datenbasis über die Merkmalsbildung bis zur Segmentierung entwickelt. Zweitens werden Segmentstrukturen durch Kennzahlen, Visualisierungen und narrative Personas anschaulich aufbereitet. Drittens werden praxisrelevante Maßnahmen für Marketing und Kundenbindung abgeleitet.

1.3 Vorgehensweise

Das Vorgehen orientiert sich am CRISP-DM-Modell. Zunächst werden theoretische Grundlagen der Kundensegmentierung und die Rolle von Validierungsmaßen erläutert. Anschließend werden die verwendeten Datensätze beschrieben und durch Feature Engineering in aussagekräftige Merkmale transformiert, unter anderem Recency, Frequency, Monetary Value sowie Warenkorb- und Sortimentsvariablen.

Die Segmentierung wird mit zwei Verfahren durchgeführt: K-Means dient als baseline für kompakte Cluster, während HDBSCAN unregelmäßige Strukturen und Rauschen abbilden kann. Die Qualität wird mit Silhouette und DBCV überprüft. Die Hopkins-Statistik wird ergänzend eingesetzt, wobei ihre eingeschränkte Aussagekraft für hochdimensionale Transaktionsdaten kritisch eingeordnet wird.

Im Ergebnisteil werden die Segmente dargestellt, mit Kennzahlen beschrieben und durch Visualisierungen anschaulich gemacht. Personas übersetzen die Ergebnisse in leicht verständliche Profile. Anschließend werden Implikationen für Marketing und CRM diskutiert. Die Arbeit schließt mit einer Reflexion der Ergebnisse, Limitationen und einem Ausblick auf zukünftige Erweiterungen.

2 Theoretischer Hintergrund

2.1 Kundensegmentierung im E-Commerce

Kundensegmentierung ist ein zentrales Instrument im Customer Relationship Management (CRM), um heterogene Kundenmengen in homogene Gruppen zu unterteilen und diese gezielt anzusprechen. Tsipstis und Chorianopoulos (2010), S. 39 betonen: “Clustering techniques identify meaningful natural groupings of records and group customers into distinct segments with internal cohesion.” Ziel ist die Entwicklung unterscheidbarer Kundentypologien, die „transparent, meaningful, and actionable“ sind (Tsipstis und Chorianopoulos (2010), S. 129).

Die Bedeutung von Kundensegmentierung im E-Commerce hat mit der Verfügbarkeit umfangreicher Transaktions- und Interaktionsdaten deutlich zugenommen. Personalisierte Angebote, zielgerichtete Kampagnen und differenzierte Kundenbindungsstrategien setzen voraus, dass heterogene Kundenmengen in konsistente Gruppen überführt werden können, die sich anhand ihres Verhaltens und Werts klar unterscheiden.

2.2 Clustering als Mittel zum Zweck

In dieser Arbeit wird Clustering nicht als Selbstzweck betrachtet, sondern als Werkzeug, um verborgene Muster zu erkennen und in verständliche Kundensegmente zu übersetzen. Zwei Verfahren stehen dabei im Mittelpunkt: K-Means und HDBSCAN.

K-Means basiert auf der Idee, die Varianz innerhalb von Clustern iterativ zu reduzieren. Es „starts with an initial cluster solution which is updated and adjusted until no further refinement is possible ... Each iteration refines the solution by reducing the within-cluster variation“ (Tsipstis und Chorianopoulos (2010), S. 85). Jedes Cluster wird dabei durch sein

Zentrum (Zentroid) repräsentiert, und die Anzahl der Cluster muss vorab festgelegt werden. Dieses Verfahren eignet sich besonders für kompakte, globuläre Strukturen.

HDBSCAN hingegen ist eine Weiterentwicklung dichtebasierter Verfahren. Dichtebasierte Ansätze identifizieren Gruppen in Regionen hoher Punktdichte und weisen spärlich besetzte Bereiche als Rauschen aus; DBSCAN nutzt dafür die Parameter ε und MinPts (Chakraborty et al. (2022), S. 87–88). Damit lassen sich auch nicht-konvexe Formen abbilden und Ausreißer explizit behandeln. K-Means eignet sich dagegen vor allem für kompakte, annähernd kugelförmige Strukturen, während hierarchische bzw. dichtebasierte Verfahren arbiträre Formen robuster erfassen können (Chakraborty et al. (2022), S. 96). HDBSCAN kombiniert diese Eigenschaften, indem es auf einer hierarchischen Betrachtung lokaler Dichten aufbaut und dadurch stabilere Cluster extrahieren kann.

Der gesamte Prozess wird im Rahmen von CRISP-DM strukturiert. Wirth und Hipp (2000), S. 4 beschreiben: „The life cycle of a data mining project is broken down in six phases“, die von Business Understanding über Data Understanding und Data Preparation bis zu Modeling, Evaluation und Deployment reichen. Diese Phasen sind nicht linear, sondern hochgradig iterativ: “it is never the case that a phase is completely done before the subsequent phase starts” (Wirth und Hipp (2000), S. 9). Eine ausführliche Darstellung und die konkrete Anwendung auf diese Arbeit finden sich in A.1: CRISP-DM-Modell.

3 Datenbasis und Aufbereitung

3.1 Roadmap der Segmentierung im Projekt

Die Abbildung Abbildung 3.1 veranschaulicht den konzeptionellen Ablauf der Segmentierung im Rahmen dieser Studie. Ausgangspunkt sind zahlreiche einzelne Beobachtungen, die in den Datensätzen Online Retail II und RetailRocket vorliegen. Diese Vielzahl an Transaktionen, Warenkörben und Interaktionen erscheint zunächst unstrukturiert und komplex.

Im nächsten Schritt werden diese Daten mithilfe von Clustering-Verfahren wie K-Means und HDBSCAN in Gruppen überführt, die gemeinsame Muster erkennen lassen. Die entstehenden Cluster verdichten sich zu interpretierbaren Segmenten, die durch Kennzahlen, Profile und Personas beschrieben werden können. Dieser Übergang macht sichtbar, dass Segmentierung nicht nur eine rechnerische Klassifikation ist, sondern eine inhaltliche Reduktion von Datenkomplexität in klar unterscheidbare Kundengruppen.

Der abschließende Teil der Abbildung symbolisiert die strategische Nutzung dieser Segmente. Auf Basis der erarbeiteten Kundengruppen können konkrete Maßnahmen für Marketing und CRM entwickelt werden. Damit endet der Prozess nicht bei der Modellierung, sondern wird in eine übergeordnete Strategie überführt, die operative Entscheidungen und Kampagnen unterstützt. Die Visualisierung verdeutlicht somit die Transformation von Rohdaten über Cluster und Segmente hin zu strategischen Maßnahmen und bildet den roten Faden für den weiteren praktischen Teil der Arbeit.

Die dargestellte Roadmap knüpft an das in A.2: Segmentation Management Strategy erläuterte Referenzmodell an. Sie macht deutlich, dass der Segmentierungsprozess als Abfolge von Transformationen zu verstehen ist, die von der Datenbasis über die Modellierung bis zur strategischen Umsetzung führen.

Im Anschluss an die Beschreibung der Datensätze erfolgt die Merkmalsbildung durch




Abbildung 3.1: Eigene Darstellung der Segmentierungs-Roadmap mit Transformation von Rohdaten über Cluster und Segmente hin zu strategischen Maßnahmen

Feature Engineering. Dabei werden aus den Rohdaten zentrale Kennzahlen wie Recency, Frequency, Monetary Value sowie warenkorb- und sortimentsbezogene Variablen abgeleitet. Erst durch diese Konstrukte wird es möglich, im nächsten Schritt Clustermodelle anzuwenden.

Schließlich wird im dritten Teil die Datenaufbereitung behandelt, die für die Robustheit der Modelle entscheidend ist. Dazu gehören die Bereinigung von Ausreißern, die Handhabung fehlender Werte sowie die Skalierung der Merkmale. Mit diesen vorbereitenden Schritten wird die Basis geschaffen, auf der die in der Roadmap dargestellte Transformation technisch und analytisch realisiert werden kann.

3.2 Datensätze Online Retail II / RetailRocket

Um die Forschungsfrage zu beantworten, welche Segmentstrukturen sich in E-Commerce-Daten verbergen und wie diese darstellbar sind, werden zwei komplementäre Datensätze genutzt. RetailRocket erfasst ereignisbasierte Interaktionen wie Ansichten, Warenkorbaktionen und Transaktionen (Zykov et al., 2022). Online Retail II hingegen stellt transaktionsbasierte Rechnungsdaten mit Artikelnummern, Mengen, Preisen und Zeitstempeln bereit (*Datasets - UCI Machine Learning Repository*, 2019).

Die Kombination beider Perspektiven erlaubt es, sowohl verhaltensnahe Muster (RetailRocket) als auch wertorientierte Strukturen (Online Retail II) zu identifizieren. Damit wird die Grundlage gelegt, um robuste und vielseitige Segmentstrukturen zu erschließen.

4 Methodik (CRISP-DM: Modeling - Theoretische Grundlagen)

4.1 Feature Engineering & Preprocessing (RFM, Warenkorbgrößen, Sortimentsmerkmale – konzeptionell)

Damit Segmentstrukturen in den Daten sichtbar werden, müssen aus den Rohdaten aussagekräftige Merkmale abgeleitet werden. Dieser Schritt wird als Feature Engineering bezeichnet (Tsiptsis und Chorianopoulos, 2010, S. 337).

Im Zentrum stehen die klassischen RFM-Variablen, die drei grundlegende Dimensionen des Kaufverhaltens beschreiben:

- *Recency* erfasst den zeitlichen Abstand seit dem letzten Kauf,
- *Frequency* gibt die Anzahl der Käufe in einem bestimmten Zeitraum wieder,
- *Monetary* misst den Umsatz im selben Zeitraum.

Durch die Kombination dieser Dimensionen können Kunden in Zellen eingeteilt werden, die Verhalten und Wert systematisch abbilden. So steht etwa die Zelle 555 für besonders wertvolle Kunden (jüngster Kauf, hohe Frequenz, hoher Umsatz), während 151 Kunden mit langer Kaufpause, geringer Frequenz und geringem Umsatz beschreibt (Tsiptsis und Chorianopoulos, 2010, S. 334–338). Diese Zellenlogik ist leicht verständlich, skaliert aber schlecht, da mit Quintilen bis zu 125 Klassen entstehen können.

Um diese Komplexität zu reduzieren, lässt sich RFM in eine kontinuierliche Kennzahl überführen. Dabei werden die drei Dimensionen zu einem gewichteten Summenscore zusammengefasst:

$$\text{RFM-Score} = w_R \cdot R + w_F \cdot F + w_M \cdot M, \quad w_R + w_F + w_M = 1.$$

Der Vorteil dieser Verdichtung liegt in der besseren Vergleichbarkeit: Statt einer Vielzahl von RFM-Zellen entsteht eine eindimensionale Metrik, die sich leicht sortieren, gruppieren und auch als Input für Clusterverfahren verwenden lässt.

Die Gewichtung der Parameter ist flexibel gestaltbar. Unternehmen können etwa den zeitlichen Abstand (Recency) stärker gewichten, wenn Reaktivierungskampagnen im Vordergrund stehen, oder die Häufigkeit (Frequency), wenn Loyalität im Fokus liegt. Durch Variation der Gewichte w_R , w_F und w_M wird unmittelbar sichtbar, wie sich die Kundenklassifikation verschiebt (Tsipitsis und Chorianopoulos, 2010, S. 338).

Eine anschauliche Visualisierung der RFM-Zellen und ihrer logischen Struktur findet sich im Anhang B.3: Retail-Segmentierung mit RFM. Dort wird die Systematik in Form eines Würfels dargestellt und um weitere Merkmale (z. B. Warenkorbgrößen, Sortimentsvielfalt) ergänzt, die im praktischen Einsatz zusätzliche Differenzierung ermöglichen.

4.2 Clustering-Verfahren (K-Means, HDBSCAN - zentrale Eigenschaften)

4.3 Validierung (Hopkins, Silhouette, DBCV) als Qualitätskontrolle

Damit die mit Clustering identifizierten Muster belastbar sind, müssen ihre Ergebnisse überprüft werden. Dazu dienen Validierungsmaße, die im Folgenden vorgestellt werden.

Die Hopkins-Statistik prüft, ob ein Datensatz überhaupt eine Clustertendenz enthält. Acito (2023), S. 271 beschreiben sie als Maß, „to assess the clustering tendency of a data set by measuring the probability that a uniform data distribution generates a given data set“. Werte über 0,75 deuten auf eine starke Clustertendenz hin, Werte nahe 0,5 auf Zufälligkeit. Bei hochdimensionalen E-Commerce-Daten ist die Aussagekraft jedoch eingeschränkt, weshalb Hopkins in dieser Arbeit nur ergänzend berücksichtigt wird.

Der Silhouette-Koeffizient bewertet die Kohäsion innerhalb von Clustern und die Separation zwischen Clustern. Er kombiniert also zwei Perspektiven: interne Homogenität und externe Abgrenzung. Tsipitsis und Chorianopoulos (2010), S. 209 nennen die Silhouette als

ein zentrales Kriterium der technischen Evaluation. Lai et al. (2025), S. 3063 ergänzen, dass sie ein objektives Maß sei, weil sie „both the cohesion within clusters and the separation between clusters“ berücksichtigt.

Es lassen sich eindimensionale und mehrdimensionale RFM-Ansätze unterscheiden. Bei der eindimensionalen RFM-Segmentierung wird nur eine der drei Dimensionen (Recency, Frequency oder Monetary) zur Einteilung von Kunden herangezogen. Kunden werden dabei typischerweise in Quantile oder Klassen gruppiert, sodass beispielsweise die 20 % der Kunden mit der höchsten Kaufhäufigkeit in die oberste Kategorie fallen (Tsiptsis und Chorianopoulos (2010), S. 333–336). Dieses Vorgehen ist leicht verständlich und ermöglicht eine schnelle Sortierung nach einzelnen Aspekten des Kaufverhaltens, bildet jedoch die Vielfalt der Kundenbeziehungen nur eingeschränkt ab. Eine detaillierte Übersicht findet sich in Anhang B.1: Eindimensionale RFM-Segmentierung.

Demgegenüber berücksichtigen mehrdimensionale Ansätze mehrere Merkmale gleichzeitig. Besonders etabliert ist die RFM-Analyse, die Recency, Frequency und Monetary Value kombiniert. Tsiptsis und Chorianopoulos (2010), S. 337 schlagen vor, „to use the respective components as inputs in a clustering model and let the algorithm reveal the underlying natural groupings of customers“. Auf diese Weise entsteht ein mehrdimensionaler Merkmalsraum, in dem differenziertere Segmente sichtbar werden. Moderne Anwendungen erweitern RFM zudem um Variablen wie Warenkorbgrößen oder Sortimentspräferenzen. Eine detaillierte Übersicht zur RFM-Segmentierung findet sich in Anhang B.2: Mehrdimensionale RFM-Segmentierung.

Für dichte-basierte Verfahren wie HDBSCAN ist der DBCV-Index geeignet. Moulavi et al. (2014), S. 839 erklären, dass DBCV die „within and between-cluster density connectedness“ misst, während Rauschen explizit berücksichtigt wird. Der Vorteil liegt darin, dass dieses Maß auch für arbiträre Clusterformen robust anwendbar ist (Moulavi et al. (2014), S. 845).

Dabei ist zu berücksichtigen, dass interne Validierungsmaße wie Silhouette oder DBCV lediglich strukturelle Eigenschaften der Clusterlösungen abbilden. Sie garantieren nicht, dass die Segmente geschäftlich relevant sind. Ohne eine anschließende inhaltliche Interpretation besteht die Gefahr, rechnerisch erzeugte Gruppen zu überinterpretieren.

Diese theoretischen Grundlagen bilden den Rahmen, um in der folgenden Untersuchung herauszuarbeiten, welche Segmentstrukturen sich in E-Commerce-Daten verbergen und wie

sie so beschrieben werden können, dass sie für Marketing und CRM unmittelbar nutzbar sind.

5 Ergebnisse und Diskussion (CRISP-DM: Modeling und Evaluation - praktisch)

5.1 Preprocessing (Bereinigung, Skalierung, Variablenableitung – Resultate, Details in Anhang C)

Die Datensätze wurden zunächst bereinigt, Duplikate und fehlerhafte Einträge entfernt sowie Rückgaben separat behandelt. Anschließend erfolgte die Vereinheitlichung der Zeitstempel und die Konstruktion abgeleiteter Variablen ($\text{Umsatz} = \text{Preis} \times \text{Menge}$). Über Recency, Frequency und Monetary Value hinaus wurden Merkmale wie Warenkorbgröße und Sortimentsvielfalt gebildet. Zur Vergleichbarkeit aller Variablen wurde eine Standardisierung angewandt. Die detaillierte Umsetzung und die Explorative Datenanalyse sind in Anhang C dokumentiert.

5.2 Clustering (K-Means und HDBSCAN – Ergebnisse und Validierung)

Zur Segmentierung wurden zwei Verfahren angewandt:

K-Means: Für verschiedene Clusterzahlen ($k = 3-8$) berechnet. Die Silhouette-Werte zeigten, dass eine 5-Cluster-Lösung eine gute Balance aus Trennschärfe und Interpretierbarkeit liefert.

HDBSCAN: Automatische Erkennung von Clustern mit variabler Dichte. Neben drei stabilen Segmenten wurde ein Teil der Kunden als Rauschen identifiziert. Der DBCV-Wert bestätigte eine robuste Abgrenzung der Cluster.

Die Validierung verdeutlicht, dass K-Means für kompakte Strukturen geeignet ist, wäh-

rend HDBSCAN flexibler auf unregelmäßige Muster reagiert.

5.3 Interpretation der Segmente (Clusterprofile, Personas, Visualisierungen)

Die Cluster wurden anhand zentraler Kennzahlen interpretiert:

Cluster 1: Häufige Käufer mit mittlerem Warenkorbwert (loyale Stammkunden).

Cluster 2: Seltene Käufer mit hohen Umsätzen (Gelegenheitskunden mit Premium-Fokus).

Cluster 3: Wenige Käufe, geringer Umsatz (Kunden mit Abwanderungsrisiko).

Cluster 4: Sehr hohe Frequenz, kleine Warenkörbe (Schnäppchenjäger).

Cluster 5 (HDBSCAN): Unregelmäßiges Kaufmuster, oft saisonal bedingt (Gelegenheitsnutzer).

Diese Segmente wurden in Personas übersetzt und durch Visualisierungen unterstützt (siehe Anhang D). Daraus lassen sich für Marketing und CRM differenzierte Maßnahmen ableiten, z. B. Reaktivierungskampagnen für Cluster 3 oder exklusive Angebote für Cluster 2.

5.4 Vergleich der Verfahren

6 Fazit und Ausblick

6.1 Beantwortung der Forschungsfrage

Die Arbeit hat gezeigt, dass sich in E-Commerce-Daten mehrere klar unterscheidbare Segmente identifizieren lassen. Diese unterscheiden sich sowohl in quantitativen Kennzahlen wie Kaufhäufigkeit, Umsatzhöhe und Sortimentspräferenzen als auch in charakteristischen Verhaltensmustern. Mit den aufbereiteten Profilen, Personas und Visualisierungen konnten die Unterschiede verständlich gemacht und in praxisnahe Maßnahmen überführt werden. Damit wurde die Forschungsfrage beantwortet, wie Segmentstrukturen in E-Commerce-Daten sichtbar gemacht und für Marketing und CRM nutzbar aufbereitet werden können.

Die eingesetzten Verfahren haben dabei ihren Zweck erfüllt. K-Means und HDBSCAN dienten als Werkzeuge, um Strukturen sichtbar zu machen. Silhouette und DBCV überprüften die Qualität der Ergebnisse. Die Hopkins-Statistik wurde ergänzend einbezogen, zeigte erwartungsgemäß kaum Clusterfähigkeit und machte deutlich, dass manche Validierungsansätze in diesem Kontext methodisch nur begrenzt aussagekräftig sind.

6.2 Limitationen

Die Ergebnisse basieren auf internen Validitätsmaßen und bieten keinen direkten Nachweis, ob segmentbasierte Maßnahmen in der Praxis zu besseren Erfolgen führen. Auch die Datenbasis weist Einschränkungen auf. Transaktions- und Eventdaten sind häufig unbalanciert, enthalten Ausreißer und bilden nicht alle relevanten Kundenmerkmale ab. Die Generalisierbarkeit auf andere Märkte oder Shops ist daher begrenzt.

6.3 Ausblick (z. B. Text Mining, Echtzeit-Segmentierung)

Für zukünftige Arbeiten empfiehlt sich die Ergänzung um externe Validierung. A/B-Tests und Uplift-Analysen könnten zeigen, ob segmentierte Kampagnen tatsächlich bessere Ergebnisse liefern. Eine Erweiterung der Merkmalsbasis durch Text Mining von Kundenbewertungen oder die Analyse von Session-Daten könnte zusätzliche Differenzierung schaffen. Auch eine dynamische Segmentierung, die sich in Echtzeit an Veränderungen im Verhalten anpasst, wäre ein sinnvoller Schritt. Schließlich sollte die Segmentlogik direkt in CRM-Systeme integriert werden, um einen geschlossenen Kreislauf zwischen Analyse, Umsetzung und Erfolgsmessung zu schaffen.

Was eine [Multi-Faktor-Authentifizierung \(MFA\)](#) ist, wird im Glossar beschrieben.

Literaturverzeichnis

- Acito, F. (2023). *Predictive Analytics with KNIME: Analytics for Citizen Data Scientists*. Springer Nature Switzerland. <https://doi.org/10.1007/978-3-031-45630-5>
- Chakraborty, S., Islam, S. H., und Samanta, D. (2022). *Data Classification and Incremental Clustering in Data Mining and Machine Learning*. Springer International Publishing. <https://doi.org/10.1007/978-3-030-93088-2>
- Datasets - UCI Machine Learning Repository. (2019, September 21). https://archive.ics.uci.edu/datasets?search=Online+Retail&utm_source=chatgpt.com
- Lai, H., Huang, T., Lu, B., Zhang, S., und Xiaog, R. (2025). Silhouette coefficient-based weighting k-means algorithm. *Neural Computing and Applications*, 37(5), 3061–3075. <https://doi.org/10.1007/s00521-024-10706-0>
- Moulavi, D., Jaskowiak, P. A., Campello, R. J. G. B., Zimek, A., und Sander, J. (2014). Density-Based Clustering Validation. *Proceedings of the 2014 SIAM International Conference on Data Mining*, 839–847. <https://doi.org/10.1137/1.9781611973440.96>
- Tsiptsis, K., und Chorianopoulos, A. (2010). *Data Mining Techniques in CRM: Inside Customer Segmentation* (1. Aufl.). Wiley. <https://doi.org/10.1002/9780470685815>
- Wirth, R., und Hipp, J. (2000). *CRISP-DM: Towards a Standard Process Model for Data Mining*. 11. <http://cs.unibo.it/~danilo.montesi/CBD/Beatriz/10.1.1.198.5133.pdf>
- Zykov, R., Noskov, A., und Anokhin, A. (2022). *Retailrocket recommender system dataset*. Kaggle.com. <https://www.kaggle.com/datasets/retailrocket/ecommerce-dataset>

Anhang

Hinweis: Alle Abbildungen in den Anhängen tragen das Präfix **A** in ihrer Nummerierung. Das **A** verweist zugleich auf den Anhang und wird fortlaufend gezählt.

Anhangsverzeichnis

Anhang A Modelle und Prozesse	17
A.1 Das CRISP-DM-Modell	18
A.2 Segmentation Management Strategy	18
Anhang B Clustering und RFM	20
B.1 Eindimensionale RFM-Segmentierung	22
B.2 Mehrdimensionale RFM-Segmentierung	22
B.3 Retail-Segmentierung mit RFM	23
Anhang C Data Preparation	27
C.1 Bereinigung (fehlende Werte, Duplikate, Rückgaben)	27
C.2 Skalierung und Transformation	37
C.3 Explorative Datenanalyse (zusätzliche Plots, Tabellen, Code)	38

Anhang A: Prozessmodelle

Dieser Anhang stellt zwei etablierte Prozessmodelle vor, die für Datenanalyse und Segmentierungsstrategien maßgeblich sind. Mit dem CRISP-DM-Referenzmodell wird ein methodischer Rahmen für die systematische Durchführung von Data-Mining-Projekten beschrieben. Ergänzend veranschaulicht die Segmentation Management Strategy, wie analytisch gewonnene Kundensegmente in strategische Marketing- und CRM-Maßnahmen überführt werden können. Die Kombination macht deutlich, dass erfolgreiche Segmentierung sowohl methodisch fundiert als auch organisatorisch eingebettet sein muss.

A.1: Das CRISP-DM-Modell

Die Abbildung A.1 zeigt das CRISP-DM-Referenzmodell mit seinen sechs Phasen Business Understanding, Data Understanding, Data Preparation, Modeling, Evaluation und Deployment. Pfeile markieren die zentralen Abhängigkeiten, während der äußere Kreis den iterativen, zyklischen Charakter des Vorgehens unterstreicht. Das Modell ist als allgemeiner Rahmen entworfen und unabhängig von Anwendungsdomäne oder eingesetzter Software.




Abbildung A.1: Das CRISP-DM-Modell nach Wirth und Hipp (2000), S. 5

Jede der sechs Phasen ist in spezifische Aufgaben untergliedert, die den Ablauf systematisieren und nachvollziehbar machen. So umfasst Data Understanding das Beschreiben, Erkunden und Überprüfen der Datenqualität, während Data Preparation Aufgaben wie Auswählen, Bereinigen, Konstruieren und Integrieren von Daten vorsieht. Modeling beinhaltet die Wahl geeigneter Verfahren, die Erstellung eines Testdesigns sowie den Aufbau und die Bewertung von Modellen. Evaluation konzentriert sich auf die Überprüfung der Ergebnisse im Hinblick auf die Projektziele, und Deployment behandelt die Bereitstellung und Nutzung der Modelle im Anwendungskontext. Wirth und Hipp betonen außerdem den stark iterativen Charakter des Modells: Ergebnisse einer Phase können jederzeit zu Rücksprüngen führen, wodurch die Arbeitsschritte flexibel angepasst werden können (Wirth und Hipp (2000), S. 6–9).

A.2: Segmentation Management Strategy

Die in Abbildung A.2 dargestellte Roadmap der *Segmentation Management Strategy* zeigt, wie analytisch ermittelte Segmente in eine unternehmerische Nutzung überführt werden können. Sie ergänzt das CRISP-DM-Modell, indem sie die Brücke von der technischen Modellierung hin zur strategischen Implementierung schlägt. Während CRISP-DM beschreibt, wie Daten zu Modellen verarbeitet werden, zeigt die Segmentation Management Strategy, wie diese Modelle in Marketing- und CRM-Maßnahmen eingebettet werden.




Abbildung A.2: Roadmap der Segmentation Management Strategy nach Tsipsis und Chorianopoulos (2010), S. 213–216

Die Roadmap besteht aus vier Schritten, die nacheinander zu durchlaufen sind:

Schritt 1: Identify the customer segments in the database

Im ersten Schritt werden die ermittelten Segmente in die Kundendatenbank integriert. Kunden erhalten Scores und werden den Segmenten zugewiesen. Tsipsis und Chorianopoulos (2010), S. 213 betonen: *“Initially the segmentation results should be deployed in the customer database. Customers should be scored and assigned into segments.”* Damit ist die organisatorische Grundlage geschaffen, auf der weitere Analysen und Maßnahmen aufbauen.

Schritt 2: Evaluate and position the segments

In einem zweiten Schritt werden die Segmente bewertet und im Marktumfeld positioniert. Dazu gehören Marktumfragen und qualitative Analysen, die Segmente mit zusätzlichen Informationen wie Bedürfnissen, Lebensstil oder Status anreichern. Zudem sollen Wettbe-

werbsvorteile, Chancen und Risiken identifiziert werden. Die Autoren halten fest, dass *“the possible opportunities and threats should be investigated in order to select the key segments to be targeted with marketing activities tailored to their profiles and needs”* (Tsiptsis und Chorianopoulos (2010), S. 214).

Schritt 3: Perform cost-benefit analysis to prioritize actions per segment

Darauf folgt eine Kosten-Nutzen-Analyse, die die Profitabilität einzelner Segmente in Relation zu den erwarteten Kosten setzt. Behavioral Drivers wie Kaufhäufigkeit oder Abwanderungsrisiken spielen dabei eine zentrale Rolle. Ziel ist die Priorisierung der Segmente nach ökonomischer Relevanz. *“Effective segmentation management requires insight into the factors that drive customer behaviors ... Finally, a cost-benefit analysis can enable the prioritization of the marketing actions to be implemented”* (Tsiptsis und Chorianopoulos (2010), S. 215).

Schritt 4: Build and deliver differentiated strategies

Im vierten Schritt werden die Segmente mit maßgeschneiderten Strategien adressiert. Spezialisierte Teams entwickeln und implementieren differenzierte Kampagnen, CRM-Maßnahmen und Produktstrategien. Dies umfasst Aspekte wie Kanalmanagement, Marketingservices, Produktmanagement und Markenführung. Tsiptsis und Chorianopoulos (2010), S. 216 schreiben hierzu: *“Each team should build and deliver specialized marketing strategies to improve customer handling, develop the relationship with customers, and increase the profitability of each segment.”*

Die Roadmap verdeutlicht, dass Segmentierung mehr ist als ein analytischer Prozessschritt. Sie muss in eine organisatorische und strategische Logik eingebettet werden, damit Segmente nicht nur statistisch existieren, sondern im Unternehmen handlungsleitend wirken. CRISP-DM liefert dafür den methodischen Rahmen, die Segmentation Management Strategy ergänzt ihn um eine explizite Managementperspektive.

Anhang B: Clustering und RFM

Dieser Anhang erläutert die RFM-Segmentierung als ein klassisches Instrument der Kundenanalyse. Im Mittelpunkt stehen die Dimensionen Recency, Frequency und Monetary Value, mit denen Kundenverhalten in strukturierte Kategorien überführt werden kann. Die Darstellung zeigt sowohl einfache eindimensionale Ansätze als auch mehrdimensionale Ausprägungen, die eine differenziertere Sicht auf Kaufmuster und Kundenwert ermöglichen. Damit wird nachvollziehbar, weshalb RFM-Modelle eine wichtige Grundlage für moderne Verfahren der Kundensegmentierung bilden.

B.1: Eindimensionale RFM-Segmentierung

Eindimensionale RFM-Segmentierung betrachtet jeweils nur eine Dimension des RFM-Modells – also Recency, Frequency oder Monetary – isoliert.

Dabei werden Kunden typischerweise in Quantile eingeteilt. So werden beispielsweise die 20 % der Kunden mit der höchsten Kaufhäufigkeit in die oberste Kategorie ($F = 5$) eingeordnet, während die 20 % mit der geringsten Häufigkeit die niedrigste Stufe ($F = 1$) bilden (Tsiptsis und Chorianopoulos, 2010, S. 333–336).

Dieser Ansatz ist leicht verständlich und ermöglicht eine schnelle Einordnung von Kunden nach einem einzelnen Aspekt des Kaufverhaltens. Allerdings bildet er die Gesamtkomplexität der Kundenbeziehungen nur eingeschränkt ab, da Interaktionen zwischen den Dimensionen unberücksichtigt bleiben.




Abbildung A.3: Beispiel für eindimensionale RFM-Einteilungen in fünf Quantile je Dimension. Hervorgehoben ist die RFM-Zelle 351 (Recency = 3, Frequency = 5, Monetary = 1) nach Tsiptsis und Chorianopoulos (2010), S. 336.

B.2: Mehrdimensionale RFM-Segmentierung

Die RFM-Analyse kombiniert drei Dimensionen: Recency, Frequency und Monetary Value. Tsiptsis und Chorianopoulos (2010), S. 336–345 beschreiben RFM als bewährten Ansatz, um

Kundenwerte differenziert abzubilden. Neben der klassischen Zellenbildung (z. B. Quintile) kann RFM auch als Input für Clustering genutzt werden. Dadurch entstehen mehrdimensionale Segmente, die sich deutlich voneinander unterscheiden. Erweiterungen des Modells beziehen zusätzliche Merkmale wie Warenkorbgrößen oder Sortimentspräferenzen ein, um die Aussagekraft weiter zu erhöhen.

B.3: Retail-Segmentierung mit RFM

Ergänzend zur theoretischen Einführung im Hauptteil wird hier die Zellenlogik von RFM veranschaulicht.

Die folgende programmgenerierte Darstellung zeigt alle möglichen Kombinationen von *Recency* und *Frequency* auf einer Ebene mit festem *Monetary*-Wert. Die Zelle 351 ist dabei als Beispiel hervorgehoben.

```
import matplotlib.pyplot as plt
from mpl_toolkits.mplot3d import Axes3D

fig = plt.figure(figsize=(12, 9))
ax = fig.add_subplot(111, projection='3d')

# RFM-Dimensionen
recency_range = range(1, 6)      # 1-5
frequency_range = range(1, 6)    # 1-5
monetary_level = 1                # Feste Ebene bei Z=1

# Vollständige Ebene bei Monetary = 1
for r in recency_range:
    for f in frequency_range:
        code = f"{r}-{f}-{monetary_level}"

        # Hervorhebung für Code "351"
        if code == "351":
            color = "red"          # Besondere Hervorhebung in rot
            text_color = "white"   # Weiße Schrift auf rot
```

```

else:
    color = "lightgrey"
    text_color = "black"      # Schwarze Schrift auf grau

    # Korrigierte Positionierung: x=r, y=f, z=monetary_level
    ax.bar3d(
        x=r-0.5, y=f-0.5, z=monetary_level-0.1, # Startposition (Ecke des
        Würfels)
        dx=1, dy=1, dz=0.2,                      # Größe
        color=color, edgecolor='black', alpha=0.9 # Weniger transparent
    )

    ax.text(
        r, f, monetary_level + 0.05, # Leicht über der Oberfläche
        code,
        color=text_color,
        ha='center', va='center',
        fontsize=14,                # Noch größere Schrift
        weight='bold',              # ALLE Texte fett
        zorder=100                  # Text immer im Vordergrund
    )

# Achsentitel (korrekte Zuordnung)
ax.set_xlabel("Recency", fontsize=12, weight='bold')
ax.set_ylabel("Frequency", fontsize=12, weight='bold')
ax.set_zlabel("Monetary", fontsize=12, weight='bold')

# Achsenticks
ax.set_xticks(range(1, 6))
ax.set_xticklabels(['1', '2', '3', '4', '5'])
ax.set_yticks(range(1, 6))
ax.set_yticklabels(['1', '2', '3', '4', '5'])
ax.set_zticks(range(1, 6))

```

```
# Achsgrenzen  
ax.set_xlim(0.5, 5.5)
```

```
ax.set_ylim(0.5, 5.5)
```

```
ax.set_zlim(0.5, 5.5)
```

```
# Seitenverhältnis & Perspektive  
ax.set_box_aspect([1, 1, 1]) # Gleiche Proportionen  
ax.view_init(elev=25, azim=45) # Bessere Sicht  
ax.grid(True)  
  
# Überschrift mit RFM-Score Berechnung  
ax.set_title("RFM-Würfel: Kontinuierlicher Score-Ansatz\n" +  
             "RFM Score = (R×wR) + (F×wF) + (M×wM)\n" +  
             "Ebene bei Monetary = 1 | Code 351 hervorgehoben",  
             fontsize=13, weight='bold', pad=20)  
  
# Layout-Anpassung ohne Warnung  
plt.subplots_adjust(left=0.1, right=0.9, top=0.85, bottom=0.1) # Mehr Platz  
für Titel  
plt.show()
```


RFM-Würfel: Kontinuierlicher Score-Ansatz
 $\text{RFM Score} = (R \times w_R) + (F \times w_F) + (M \times w_M)$
 Ebene bei Monetary = 1 | Code 351 hervorgehoben




Abbildung A.4: Eigene Darstellung eines RFM-Würfels

Die Abbildung zeigt einen zweidimensionalen Ausschnitt des RFM-Modells in Würfelform:

- Die x-Achse steht für *Recency* (Zeit seit dem letzten Kauf).
- Die y-Achse repräsentiert *Frequency* (Kaufhäufigkeit).
- Die z-Achse bildet *Monetary* (Umsatzhöhe) ab. In dieser Darstellung ist die Ebene mit *Monetary* = 1 ausgewählt.

Jede Zelle im Würfel steht für eine Kombination dieser drei Dimensionen und wird durch einen dreistelligen Code gekennzeichnet (z. B. 351 = Recency 3, Frequency 5, Monetary 1).

Die hervorgehobene Zelle 351 veranschaulicht exemplarisch, wie einzelne Kundengruppen identifiziert werden können. Damit wird deutlich, dass das RFM-Schema ein Raster bildet, das eine differenzierte Beschreibung von Kundenverhalten ermöglicht.

Anhang C: Data Preparation und Zusatzanalysen

C.1: Bereinigung (fehlende Werte, Duplikate, Rückgaben)

Zur Sicherstellung der Datenqualität wurden folgende Schritte durchgeführt:

- Übersicht der fehlenden Werte vor der Bereinigung
- Entfernen von Duplikaten (`distinct()`)
- Ausschluss von Beobachtungen ohne Kunden-ID
- Entfernung von Stornierungen und negativen Mengen
- Vereinheitlichung der Zeitstempel

C.1: Bereinigung (fehlende Werte, Duplikate, Rückgaben)

```
# EINSTELLUNGEN
DELETE_OLD_PLOTS <- FALSE # ← Ein-/Ausschalter hier setzen

# Pakete laden
library(dplyr)
library(ggplot2)
library(patchwork)
library(corrplot)
library(tidyr)
library(knitr)
library(gt)

# Alte Plots löschen (nur wenn aktiviert)
if (DELETE_OLD_PLOTS && dir.exists("img/Abbildungen")) {
  old_files <- list.files("img/Abbildungen", pattern = "*.png", full.names =
TRUE)
```

```
if (length(old_files) > 0) {  
  file.remove(old_files)  
  cat(" ", length(old_files), "alte Plot(s) gelöscht\n")  
}  
} else if (!DELETE_OLD_PLOTS) {  
  cat(" Löschen der alten Plots ist deaktiviert\n")  
}
```

Terminal-Output

Löschen der alten Plots ist deaktiviert

```
# Verzeichnis erstellen (falls nicht vorhanden)  
if (!dir.exists("img/Abbildungen")) {  
  dir.create("img/Abbildungen", recursive = TRUE)  
}  
  
# Datensatz laden und vorbereiten  
retail <- read.csv("data/OR2/online_retail_II.csv")  
  
# Datensatz bereinigen  
retail_clean <- retail %>%  
  distinct() %>%  
  filter(!is.na(Customer.ID)) %>%  
  filter(!grepl("^C", Invoice)) %>%  
  filter(Quantity > 0, Price > 0)  
  
cat("Bereinigte Daten:", nrow(retail_clean), "Zeilen\n")
```

Terminal-Output

Bereinigte Daten: 779425 Zeilen

```
# Alle Variablen erstellen
retail_viz <- retail_clean %>%
  mutate(
    Revenue = Quantity * Price,
    LogQuantity = log(Quantity + 1),
    LogPrice = log(Price + 1),
    LogRevenue = log(Revenue + 1)
  ) %>%
  select(Quantity, Price, Revenue, LogQuantity, LogPrice, LogRevenue)

# Daten für Plotting vorbereiten
retail_long <- retail_viz %>%
  pivot_longer(everything(), names_to = "Variable", values_to = "Value")

# PLOT 1: Verteilungen erstellen und speichern
p1 <- ggplot(retail_long, aes(x = Value)) +
  geom_histogram(bins = 50, fill = "steelblue", alpha = 0.7, color = "black")
+
  facet_wrap(~Variable, scales = "free", ncol = 3) +
  theme_minimal() +
  labs(
    title = "Verteilungen der E-Commerce Kennzahlen",
    subtitle = paste("Basiert auf", nrow(retail_clean), "Transaktionen"),
    x = "Wert", y = "Häufigkeit"
  ) +
  theme(
    strip.text = element_text(face = "bold", size = 10),
    plot.title = element_text(face = "bold", size = 14),
    axis.text = element_text(size = 9),
    axis.title = element_text(size = 10)
  )

ggsave("img/Abbildungen/verteilungen_ecommerce.png", p1,
  width = 10, height = 6, dpi = 300)
```

```
cat(" Plot 1 gespeichert: img/Abbildungen/verteilungen_ecommerce.png\n")
```

Terminal-Output

```
Plot 1 gespeichert: img/Abbildungen/verteilungen_ecommerce.png
```

```
# PLOT 2: Korrelationsmatrix erstellen und speichern
correlation_matrix <- cor(retail_viz, use = "complete.obs")

png("img/Abbildungen/korrelationsmatrix.png", width = 10*300, height = 8*300,
res = 300)
corrplot(correlation_matrix,
          method = "color", type = "upper", order = "hclust",
          tl.col = "black", tl.srt = 45, addCoef.col = "black",
          number.cex = 0.8, col = colorRampPalette(c("red", "white",
"blue"))(200),
          title = "Korrelationsmatrix - Online Retail Variablen", mar =
c(0,0,2,0))
dev.off()
```

Terminal-Output

```
pdf
2
```

```
cat(" Plot 2 gespeichert: img/Abbildungen/korrelationsmatrix.png\n")
```

Terminal-Output

```
Plot 2 gespeichert: img/Abbildungen/korrelationsmatrix.png
```

```
# PLOT 3: Scatterplots erstellen und speichern
cat("Verwende vollständigen Datensatz:", nrow(retail_viz), "Transaktionen für
Scatterplots\n")
```

 Terminal-Output

Verwende vollständigen Datensatz: 779425 Transaktionen für Scatterplots

```
p3a <- ggplot(retail_viz, aes(x = Quantity, y = Price)) +
  geom_point(alpha = 0.4, size = 0.8, color = "steelblue") +
  geom_smooth(method = "lm", color = "red", se = TRUE, linewidth = 1) +
  theme_minimal() +
  labs(title = "Quantity vs. Price", x = "Menge", y = "Preis") +
  theme(plot.title = element_text(face = "bold", size = 11))

p3b <- ggplot(retail_viz, aes(x = LogQuantity, y = LogPrice)) +
  geom_point(alpha = 0.4, size = 0.8, color = "darkgreen") +
  geom_smooth(method = "lm", color = "red", se = TRUE, linewidth = 1) +
  theme_minimal() +
  labs(title = "Log(Quantity) vs. Log(Price)", x = "Log(Menge)", y =
"Log(Preis)") +
  theme(plot.title = element_text(face = "bold", size = 11))

p3c <- ggplot(retail_viz, aes(x = Quantity, y = Revenue)) +
  geom_point(alpha = 0.4, size = 0.8, color = "purple") +
  geom_smooth(method = "lm", color = "red", se = TRUE, linewidth = 1) +
  theme_minimal() +
  labs(title = "Quantity vs. Revenue", x = "Menge", y = "Umsatz") +
  theme(plot.title = element_text(face = "bold", size = 11))

p3d <- ggplot(retail_viz, aes(x = Price, y = Revenue)) +
  geom_point(alpha = 0.4, size = 0.8, color = "orange") +
  geom_smooth(method = "lm", color = "red", se = TRUE, linewidth = 1) +
  theme_minimal() +
  labs(title = "Price vs. Revenue", x = "Preis", y = "Umsatz") +
  theme(plot.title = element_text(face = "bold", size = 11))

p3_combined <- (p3a | p3b) / (p3c | p3d) +
  plot_annotation(
```

```

    title = "Scatterplot-Matrix: Wichtige Beziehungen",
    theme = theme(plot.title = element_text(face = "bold", size = 14, hjust =
0.5))
  )

ggsave("img/Abbildungen/scatterplots_beziehungen.png", p3_combined,
       width = 10, height = 8, dpi = 300)
cat(" Plot 3 gespeichert: img/Abbildungen/scatterplots_beziehungen.png\n")

```

Terminal-Output

```
Plot 3 gespeichert: img/Abbildungen/scatterplots_beziehungen.png
```

```

# PLOT 4: Boxplots erstellen und speichern
retail_long_scaled <- retail_viz %>%
  mutate_all(scale) %>%
  pivot_longer(everything(), names_to = "Variable", values_to = "Value")

p4 <- ggplot(retail_long_scaled, aes(x = Variable, y = Value, fill =
Variable)) +
  geom_boxplot(alpha = 0.7, outlier.size = 0.3) +
  theme_minimal() +
  theme(
    axis.text.x = element_text(angle = 45, hjust = 1, size = 9),
    axis.text.y = element_text(size = 8),
    axis.title = element_text(size = 10),
    plot.title = element_text(face = "bold", size = 12),
    plot.subtitle = element_text(size = 9)
  ) +
  labs(
    title = "Standardisierte Verteilungen im Vergleich",
    subtitle = "Boxplots zeigen Median, Quartile und Ausreißer",
    x = "Variable", y = "Standardisierter Wert"
  ) +

```

```
guides(fill = "none")

ggsave("img/Abbildungen/boxplots_verteilungen.png", p4,
       width = 10, height = 4, dpi = 300)
cat(" Plot 4 gespeichert: img/Abbildungen/boxplots_verteilungen.png\n")
```

Terminal-Output

```
Plot 4 gespeichert: img/Abbildungen/boxplots_verteilungen.png
```

```
cat("\n Alle Plots erfolgreich erstellt und gespeichert!\n")
```

Terminal-Output

```
Alle Plots erfolgreich erstellt und gespeichert!
```

6.3.1 Verteilungen der E-Commerce Kennzahlen

Die Analyse der Datenverteilungen zeigt charakteristische Muster für E-Commerce-Transaktionen:

6.3.2 Korrelationsstruktur der Variablen

Die Korrelationsmatrix verdeutlicht die Zusammenhänge zwischen den verschiedenen Kennzahlen:

6.3.3 Scatterplot-Matrix wichtiger Beziehungen

Die Scatterplots zeigen die Beziehungen zwischen zentralen Variablen auf:

6.3.4 Standardisierte Verteilungen im Vergleich

Die Boxplots ermöglichen einen direkten Vergleich der Variablenverteilungen:

```
# Deskriptive Statistiken (nutzt die bereits geladenen Daten)
summary_stats <- retail_viz %>%
```





Abbildung A.5: Verteilungen der wichtigsten Variablen

```
summarise(
  across(everything(), list(
    Missing = ~sum(is.na(.)),
    `Missing %` = ~round(sum(is.na(.)) / length(.) * 100, 1),
    Distinct = ~n_distinct(.),
    Min = ~round(min(., na.rm = T), 2),
    Median = ~round(median(., na.rm = T), 2),
    Max = ~round(max(., na.rm = T), 2),
    Mean = ~round(mean(., na.rm = T), 2),
    SD = ~round(sd(., na.rm = T), 2)
  ))
) %>%
pivot_longer(everything(), names_to = c("Variable", "Statistic"), names_sep = "_") %>%
pivot_wider(names_from = Statistic, values_from = value)

# GT-Tabelle für PDF
```




Abbildung A.6: Korrelationsmatrix der E-Commerce Variablen




Abbildung A.7: Wichtige Scatterplot-Beziehungen




Abbildung A.8: Standardisierte Verteilungen im Vergleich

Deskriptive Statistiken - Online Retail Dataset

Basiert auf 779425 Transaktionen

Variable	Missing	Missing %	Distinct	Min	Median	Max	Mean	SD
Quantity	0	0	437	1.00	6.00	80,995.00	13.49	145.86
Price	0	0	665	0.00	1.95	10,953.50	3.22	29.68
Revenue	0	0	3919	0.00	12.48	168,469.60	22.29	227.43
LogQuantity	0	0	437	0.69	1.95	11.30	1.92	1.00
LogPrice	0	0	665	0.00	1.08	9.30	1.17	0.60
LogRevenue	0	0	3664	0.00	2.60	12.03	2.48	1.01

```
summary_stats %>%
  gt() %>%
  tab_header(
    title = "Deskriptive Statistiken - Online Retail Dataset",
    subtitle = paste("Basiert auf", nrow(retail_clean), "Transaktionen")
  ) %>%
  tab_style(
    style = cell_text(weight = "bold"),
    locations = cells_column_labels()
  ) %>%
  tab_style(
    style = cell_text(weight = "bold"),
    locations = cells_body(columns = Variable)
  ) %>%
  fmt_number(
    columns = c(Min, Median, Max, Mean, SD),
    decimals = 2
  ) %>%
  tab_options(
    table.font.size = 10,
    heading.title.font.size = 12,
    heading.subtitle.font.size = 10
  )
```

C.2: Skalierung und Transformation

C.3: Explorative Datenanalyse (zusätzliche Plots, Tabellen, Code)

Glossar

Multi-Faktor-Authentifizierung (MFA) eine Sicherheitsmethode, die eine zusätzliche Verifikationsebene erfordert, beispielsweise durch eine Kombination aus Passwort und biometrischer Authentifizierung.

Ehrenwörtliche Erklärung

Hiermit erkläre ich, dass ich die vorliegende Studienarbeitselbstständig angefertigt habe.
Es wurden nur die in der Arbeit ausdrücklich benannten Quellen und Hilfsmittel benutzt.
Wörtlich oder sinngemäß übernommenes Gedankengut habe ich als solches kenntlich gemacht.
Diese Arbeit hat in gleicher oder ähnlicher Form noch keiner Prüfungsbehörde vorgelegen.

Bielefeld, den 30. September 2025



Christian Roth